



中南大學

CENTRAL SOUTH UNIVERSITY

CSE

计算机学院

计算机视觉前沿技术

注意力机制

主讲： 沈成超

邮箱： scc.cs@csu.edu.cn

2026.03.27

目录



1. 前言
2. 注意力机制原理
3. 注意力核心概念
4. 注意力机制类型
5. 其他相关概念
6. Transformer

1.前言：人类的视觉注意力

Media: Diapers-01.jpg
Time: 20:00:00.000 - 00:00:06.033
Participant: User_00



Extra gentle for the most sensitive skin.

So gentle for sensitive skin, add the chemicals and moisture of a diaper and you have diaper rash.


Baby Wipes's unique high-absorbency natural-blend cotton blend provides cotton-soft, extra thick, gel-free protection for your baby's sensitive skin. The chlorine-free materials and absorbent polymers is non-toxic and non-irritating. Clinically tested and pediatrician recommended for babies with allergies and sensitive skin.



If you are not satisfied with the baby leakage protection, you will get your money back. Read more about our leakfree guarantee at www.baby.com


- 人类视觉的“局部聚焦”
- 注意力高度集中于显著特征，背景信息（文案）被忽略
- 面对海量信息，如何避免关键内容“失焦”？

1. 前言：人类的视觉注意力



- 动态的“注意力引导”
- 随着婴儿朝右看，读者的注意力会被婴儿的视线引导至右侧文字
- 视觉焦点（权重）从单一点位，精准转移至目标信息
- 能否让神经网络也拥有这种“主动聚焦”的能力？

2.注意力机制原理： 编码-解码模型



对于解码器Decoder来说，其任务是根据句子Source的中间语义表式 c 和之前已经生成的历史信息 $y_1, y_2, \dots, y_{i-1}$ 来逐个生成 i 时刻要生成的单词：

$$y_i = f(c, y_1, y_2, \dots, y_{i-1})$$

2.注意力机制原理:编码-解码模型分析

$$y_i = f(c, y_1, y_2, \dots, y_{i-1})$$



$$y_1 = f(c)$$

$$y_2 = f(c, y_1)$$


$$y_3 = f(c, y_1, y_2)$$

无论翻译哪一个目标单词，所使用的输入句子Source的语音编码 c 都是一样的,没有任何的区别。

句子Source中任意单词对生成某个目标单词 y_i 来说影响力都是相同的，也就是说这个模型没有对输入的信息进行优选，没有体现出注意力，这类似于人类看到眼前的画面，但是眼中却没有注意焦点一样!没有注意力机制的编码-解码模型实际上是一个分心模型!


2. 注意力机制原理:注意力机制的引入

(Tom,0.6) (Chase,0.2) (Jerry,0.2)



- 每个英文单词的概率代表了翻译当前单词“杰瑞”时，注意力分配模型分配给不同英文单词的注意力大小。
- 注意力机制的核心作用，就是让模型在翻译时动态聚焦于与当前目标词最相关的源端信息，从而大幅提升翻译的准确性与语义一致性。

2. 注意力机制原理:注意力层



- 注意力层明确选择相关信息
 - 它的存储器 (memory) 由 “键值对” 组成
 - 键和查询越相似, 则输出的值越相近

2.注意力机制原理:注意力层


- 假设“一条询问”为 $\mathbf{q} \in \mathbb{R}^{d_q}$, 存储器为 $(\mathbf{k}_1, \mathbf{v}_1), \dots, (\mathbf{k}_n, \mathbf{v}_n)$; $\mathbf{k}_i \in \mathbb{R}^{d_k}$, $\mathbf{v}_i \in \mathbb{R}^{d_v}$
 - 计算注意力分数 $a_1, \dots, a_n$; $a_i = \alpha(\mathbf{q}, \mathbf{k}_i)$
 - 使用 softmax 获得注意力
- 改变 α 可以获得不同的注意力层

$$b_1, \dots, b_n = \text{softmax}(a_1, \dots, a_n)$$

- 输出是值的加权和

$$\mathbf{o} = \sum_{i=1}^n b_i \mathbf{v}_i$$

3.注意力核心概念：注意力评分函数



- 评分函数的核心作用是计算查询向量与键向量的相似度
- 为每个输入位置分配注意力权重，从而让模型聚焦重要信息、弱化无关信息

3.注意力核心概念：注意力评分函数

加性注意力

一般来说，当查询和键是不同长度的矢量时，可以使用加性注意力作为评分函数。给定查询 $q \in \mathbb{R}^q$ 和 $k \in \mathbb{R}^k$ ，加性注意力的评分函数为

$$a(q, k) = w_v^\top \tanh(w_q q + W_k k) \in \mathbb{R}$$

如上所示，将查询和键连结起来后输入到一个多层感知机（MLP）中，感知机包含一个隐藏层，其隐藏单元数是一个超参数 h 。使用 $\tanh$ 作为激活函数，并且禁用偏置项。

3.注意力核心概念：注意力评分函数

缩放点积注意力

点积评分函数计算高效，但要求查询与键维度相同。为消除维度 d 对点积方差的影响，将点积除以 $\sqrt{d}$ ，得到缩放点积注意力评分函数：

$$a(q, k) = q^T k / \sqrt{d}$$

在实践中，我们通常从小批量的角度来考虑提高效率，例如基于 n 个查询和 m 个键 - 值对计算注意力，其中查询和键的长度为 d ，值的长度为 v 。查询 $Q \in \mathbb{R}^{n \times d}$ 、键 $K \in \mathbb{R}^{m \times d}$ 和值 $V \in \mathbb{R}^{m \times v}$ 的缩放点积注意力是：

$$\text{softmax}\left(\frac{QK^T}{\sqrt{d}}\right)V \in \mathbb{R}^{n \times v}$$

3.注意力核心概念：计算注意力汇聚的输出为值的加权和


用数学语言描述，假设有一个查询 $q \in \mathbb{R}^q$ 和 m 个键值对 $(k_1, v_1), \dots, (k_m, v_m)$ ，其中 $k_i \in \mathbb{R}^k$ ， $v_i \in \mathbb{R}^v$ 。注意力汇聚函数 f 就被表示成值的加权和：

$$f(q, (k_1, v_1), \dots, (k_m, v_m)) = \sum_{i=1}^m \alpha(q, k_i) v_i \in \mathbb{R}^v$$

其中查询 q 和键 k_i 的注意力权重是通过注意力评分函数 α 将两个向量映射成标量，再经过 softmax 运算得到的：

$$\alpha(q, k_i) = \text{softmax}(a(q, k_i)) = \frac{\exp(a(q, k_i))}{\sum_{j=1}^m \exp(a(q, k_j))} \in \mathbb{R}$$

4. 注意力机制类型：多头注意力




$$\mathbf{W}_q^{(i)} \in \mathbb{R}^{p_q \times d_q}, \mathbf{W}_k^{(i)} \in \mathbb{R}^{p_k \times d_k}, \text{ and } \mathbf{W}_v^{(i)} \in \mathbb{R}^{p_v \times d_v}$$


$$\mathbf{o}^{(i)} = \text{attention}(\mathbf{W}_q^{(i)} \mathbf{q}, \mathbf{W}_k^{(i)} \mathbf{k}, \mathbf{W}_v^{(i)} \mathbf{v})$$

for $i = 1, \dots, h$

$$\mathbf{o} = \mathbf{W}_o \begin{bmatrix} \mathbf{o}^{(1)} \\ \vdots \\ \mathbf{o}^{(h)} \end{bmatrix}$$



4. 注意力机制类型：自注意力



- 有了注意力机制之后，我们将词元序列输入注意力池化中，以便同一组词元同时充当查询、键和值。
- 具体来说，每个查询都会关注所有的键 - 值对并生成一个注意力输出。由于查询、键和值来自同一组输入，因此被称为自注意力（self-attention）

5. 位置编码

为了使用序列的顺序信息，通过在输入表示中添加位置编码（positional encoding）来注入绝对或相对的位置信息。位置编码可以通过学习得到也可以直接固定得到。接下来描述的是基于正弦函数和余弦函数的固定位置编码

假设输入表示 $X \in \mathbb{R}^{n \times d}$ 包含一个序列中 n 个词元的 d 维嵌入表示。位置编码使用相同形状的位置嵌入矩阵 $P \in \mathbb{R}^{n \times d}$ 输出 $X + P$ ，矩阵第 i 行、第 $2j$ 列和 $2j + 1$ 列上的元素为：

$$p_{i,2j} = \sin\left(\frac{i}{10000^{2j/d}}\right)$$

$$p_{i,2j+1} = \cos\left(\frac{i}{10000^{2j/d}}\right)$$

5. 位置编码：相对位置信息

除了捕获绝对位置信息之外，上述的位置编码还允许模型学习得到输入序列中相对位置信息。这是因为对于任何确定的位置偏移 δ ，位置处 $i + \delta$ 的位置编码可以线性投影位置 i 处的位置编码来表示。

这种投影的数学解释是，令 $\omega_j = 1/10000^{\frac{2j}{d}}$ ，对于任何确定的位置偏移 δ ，公式中的任何一对元素 $(p_{i,2j}, p_{i,2j+1})$ 都可以线性投影到 $(p_{i+\delta,2j}, p_{i+\delta,2j+1})$ ：


$$\begin{aligned} & \begin{bmatrix} \cos(\delta\omega_j) & \sin(\delta\omega_j) \\ -\sin(\delta\omega_j) & \cos(\delta\omega_j) \end{bmatrix} \begin{bmatrix} p_{i,2j} \\ p_{i,2j+1} \end{bmatrix} \\ &= \begin{bmatrix} \cos(\delta\omega_j)\sin(i\omega_j) + \sin(\delta\omega_j)\cos(i\omega_j) \\ -\sin(\delta\omega_j)\sin(i\omega_j) + \cos(\delta\omega_j)\cos(i\omega_j) \end{bmatrix} \\ &= \begin{bmatrix} \sin((i+\delta)\omega_j) \\ \cos((i+\delta)\omega_j) \end{bmatrix} \\ &= \begin{bmatrix} p_{i+\delta,2j} \\ p_{i+\delta,2j+1} \end{bmatrix}, \end{aligned}$$

2×2 投影矩阵不依赖于任何位置的索引 i

5.添加与归一化

添加与归一化

- 层规范 (Layer Norm) 类似于批量规范 (Batch Norm)
- 但是平均值和方差是沿最后一个维度计算的
 $X.\text{mean}(\text{axis} = -1)$



6. Transformer

- 编码器 - 解码器架构

