



中南大學

CENTRAL SOUTH UNIVERSITY

计算机视觉前沿技术

CSE

计算机学院

Transformer

主讲： 沈成超

邮箱： scc.cs@csu.edu.cn


2026.04.17

目录



1. Encoder-Decoder架构
2. Encoder-only架构
3. Decoder-only架构
4. 课程作业

1. Encoder-Decoder: Transformer



Encoder端 (语义理解) :

- 多头自注意力机制
- 双向注意力 (无Mask)
- 前馈神经网络

Decoder端 (编码转换) :

- 带掩码的多头自注意力 (Causal Mask)
- 交叉注意力 (Encoder编码特征)
- 前馈神经网络

1. Encoder-Decoder: Transformer (语言翻译)

- 自注意力机制计算

$$Attention(Q, K, V) = softmax\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

- 残差连接与层归一化

$$Output = LayerNorm(x + Sublayer(x))$$

$Sublayer(x)$ 代表当前子层的输出

1. Encoder-Decoder: Transformer (语言翻译)

- 前馈神经网络

$$FFN(x) = \max(0, xW_1 + b_1)W_2 + b_2$$

- 正弦波位置编码


$$p_{i,2j} = \sin\left(\frac{i}{10000^{2j/d}}\right)$$

$$p_{i,2j+1} = \cos\left(\frac{i}{10000^{2j/d}}\right)$$

i : 位置, 即该Token在序列中的位置

j : 特征维度位置, 在整个特征中的位置

2. Encoder-Only架构: BERT (文本理解)



纯编码器架构:

由多层Transformer Encoder Block堆叠构成

全局双向视野:

移除了掩码机制, 获取完整上下文

2. Encoder-Only架构: BERT (文本理解)

- 双重预训练任务

掩码语言模型 + 下一句预测

- 奠定了“预训练 + 微调”范式

- 复合输入特征融合



$$E = E_t + E_s + E_p$$

- E_t 为词嵌入;
- E_s 为区分不同句子的片段嵌入;
- E_p 为可学习的绝对位置编码

- 无掩码的注意力机制

$$Attention(Q, K, V) = softmax\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$

2. Encoder-Only架构: ViT (图像理解)



图像块 (Patch) 划分:

将完整的高维输入图像切割为固定大小区块

线性投影映射:

二维 $\rightarrow$ 一维 $\rightarrow$ 固定维度的Token

CLS Token:

额外的可学习向量, 用于图像分类

2. Encoder-Only架构: ViT (图像理解)

- 打破模态壁垒
- 图像序列化
- 输入分辨率: $H \times W$, 通道数为 C 的原始图像 $x \in \mathbb{R}^{H \times W \times C}$, 设定区块大小为 $P \times P$, 将其切分为展平的二维块序列 $x_p \in \mathbb{R}^{N \times (P^2 \cdot C)}$, 其中有效序列长度

$$N = \frac{H \times W}{P^2}$$

- Patch嵌入与位置先验

$$z_0 = [x_{\text{class}}, x_p^1 E, x_p^2 E, \dots, x_p^N E] + E_{\text{pos}} \quad E_{\text{pos}} \in \mathbb{R}^{(N+1) \times D}$$

2. Encoder-Only架构: Swin Transformer (图像理解)

层次化特征构建:


降低空间分辨率, 增加通道数

基于窗口的自注意力:


将整图划分为多个互不重叠的局部窗口

移动窗口 (Shifted Windows) 机制:

平移窗口使得上层中的边缘Patch在下一层划分到一个新窗口中



2. Encoder-Only架构: Swin Transformer (图像理解)



- Swin Transformer (W-MSA) 与 ViT(MSA)计算复杂度对比


$$\Omega(MSA) = 4hwC^2 + 2(hw)^2C$$

$$\Omega(W-MSA) = 4hwC^2 + 2M^2hwC$$

- 相对位置偏置(B:偏置矩阵)

$$Attention(Q, K, V) = softmax\left(\frac{QK^T}{\sqrt{d_k}} + B\right)V$$

2. Encoder-Only架构: DiT (图像生成)



潜空间切块:

压缩图像至低维潜空间 (*Latent Diffusion 2022*)

自适应层归一化:

利用条件向量直接回归出归一化层的缩放和平移参数

2. Encoder-Only架构: DiT (图像生成)

- 扩散模型的去噪目标函数
- 给定时间步 t 和条件 c , 预测并去除潜变量 z_t 中添加的高斯噪声 ϵ

$$\mathcal{L}(\theta) = E_{z_0, \epsilon, t, c} [\|\epsilon - \epsilon_\theta(z_t, t, c)\|^2]$$

- 自适应层归一化机制
- 对于特征 x , 条件向量 c , 通过一个MLP动态回归出维度一致的缩放和平移因子 γ_c, β_c , 直接作用于标准化后的特征

$$adaLN(x, c) = \gamma_c \odot \left(\frac{x - \mu}{\sigma} \right) + \beta_c$$


- adaLN-Zero的残差缩放
- 引入维度缩放参数 α_c , 每一个DiT Block的完整输出形式为

$$x_{out} = x_{in} + \alpha_{c,1} \odot Attention(adaLN_1(x_{in})) + \alpha_{c,2} \odot FFN(adaLN_2(...))$$

2. Encoder-Only架构: DiT (图像生成)



3. Decoder-Only架构: GPT (语言续写)



纯解码器 (Decoder) 架构:

仅保留自注意力层+前馈网络层

掩码自注意力:

引入一个下三角掩码矩阵, 屏蔽当前Token之后的所有未来信息

自回归生成:

从左至右, 逐词生成

3. Decoder-only架构: GPT

- 开创了生成式预训练范式
- 掩码自注意力计算

$$Attention(Q, K, V) = softmax\left(\frac{QK^T}{\sqrt{d_k}} + M\right)V$$


当 $i < j$ 时, $M_{ij} = -\infty$; 否则 $M_{ij} = 0$

- 自回归语言模型目标函数
- 给定一个无标签的文本序列 $U = \{u_1, u_2, \dots, u_n\}$
- 模型通过参数 θ 最大化以下对数似然

$$\mathcal{L}(U) = \sum_i \log P(u_i | u_{i-k}, \dots, u_{i-1}; \theta)$$

k 为上下文窗口大小

3. Decoder-only架构: LLaMA



位置编码重构:

引入旋转位置编码, 在内积计算阶段
动态注入相对位置信息

前置简化归一化层:


在 Attention 和 FFN 计算之前进行归一化
采用RMS Norm替换Layer Norm

升级激活函数:

将前馈神经网络中的ReLU激活函数替
换为SwiGLU

3. Decoder-Only架构: LLaMA

- Group Query Attention (节省KV显存)



3. Decoder-Only架构: LLaMA

- 均方根归一化 (简化计算, 降低延迟)

$$RMSNorm(x) = \frac{x}{\sqrt{\frac{1}{d} \sum_{i=1}^d x_i^2 + \epsilon}} \odot \gamma$$

- 旋转位置编码


$$R_m = \begin{pmatrix} \cos m\theta & -\sin m\theta \\ \sin m\theta & \cos m\theta \end{pmatrix}$$

$$(R_m q)^\top (R_n K) = q^\top R_m^\top R_n k = q^\top R_{n-m} k$$

3. Decoder-Only架构: LLaMA

- 门控激活函数

$$\text{SwiGLU}(x, W, V) = \text{Swish}(xW) \otimes (xV)$$



3. Decoder-only架构: Qwen

- 架构与LLaMA基本一致
- 超大词表重构 → 针对多语言（特别是中文）进行了深度优化 → 152K 的分词词表
- 独立映射权重 → 解绑词嵌入层和最终输出层 → 参数量换生成质量
- 全链路对齐 → 模型训练完后，引入SFT与RLHF → 输出符合人类偏好与安全规范

4.课程作业：用Numpy实现MLP进行Mnist分类

- ViT架构，采用绝对位置编码（cosine-sine编码、或可学习编码）
- 2个Transformer Encoder Block（每个Block：Attention + MLP）
- 数据集读取及预处理，采样完整训练集（ViT数据饥渴，数据少容易过拟合）
- Attention模块的梯度计算、反向传播、参数更新（AdamW优化器）
- 强数据增强（Crop, Color Jit, Resize等等）
- 损失函数，验证集准确率曲线