



中南大學

CENTRAL SOUTH UNIVERSITY

计算机视觉前沿技术

CSE

计算机学院

强化学习核心概念

主讲： 沈成超

邮箱： scc.cs@csu.edu.cn

2026.05.08

目录




1. 强化学习概述
2. 核心要素与交互逻辑
3. 核心算法思想
4. 其它
5. 课程总结

1. 强化学习概述:定义


核心定义

强化学习是**让一个智能体通过与环境交互，在试错中学习策略，以最大化长期累积奖励的机器学习方法。**

- 学习方式：边行动、边观察、边修正
- 核心挑战：延迟回报与序列决策
- 典型代表：走迷宫机器人 (Trial and Error)



1. 强化学习概述：例子



场景规则设定

- 状态：机器人在迷宫中的实时坐标(x,y)
- 动作：可执行“上、下、左、右”四个方向的移动
- 奖励：撞墙 **-1** | 每步 **-0.1** | 到达终点 **+100**

学到什么？

- 哪些路线更容易到达终点
- 哪些动作经常导致失败
- 有些动作虽然短期看吃亏，但长期更有利

1. 强化学习概述：对比

方面	监督学习 (SL)	强化学习 (RL)
数据来源	固定标注数据集	与环境交互生成
学习目标	特征到标签的静态映射	最大化长期累计收益
反馈形式	每个样本均有标准答案	只有奖励信号，且可能延迟
数据分布	相对固定	会随着策略变化而变化
核心挑战	泛化能力	探索、稳定训练与信度分配

2. 核心要素与交互逻辑：核心要素

六大核心要素

- 智能体(Agent): 做决策的主体
- 环境(Environment): 智能体所处的外部世界
- 状态(Status): 当前局面
- 动作(Action): 智能体可以采取的行为
- 奖励(Reward): 环境给出的反馈
- 策略(Policy): 在不同状态下如何选择动作的规则

2. 核心要素与交互逻辑：动作空间

离散动作空间

定义：可选动作的数量是有限的、可数的。

典型示例：

- 游戏操作：上下左右移动
- 棋牌博弈：落子位置
- 金融交易：买入、卖出资产

连续动作空间

定义：动作取值为实数或向量，分布在连续区间内，数量无限。

典型示例：

- 机器控制：机械臂关节旋转角度
- 自动驾驶：方向盘的转向角度
- 无人机飞行：飞行姿态的连续微调

2. 核心要素与交互逻辑：核心目标

强化学习的本质是优化长期回报(Return)，即智能体在做决策时，不应只着眼于当前步骤的即时奖励，更要综合考量从当下开始的未来所有奖励的总和。

Return 定义

$$G_t = r_{t+1} + \gamma \cdot r_{t+2} + \gamma^2 \cdot r_{t+3} + \dots + \gamma^k \cdot r_{t+k} + \dots$$

G_t (总回报)

从当前时刻 t 开始，
未来所有奖励的加权总和

r_{t+k} (即时奖励)

智能体在未来第 k
与环境交互后获得的反馈。

γ (折扣因子)

取值 $[0, 1]$ ，用于对远期回报
进行“打折扣”处理。

2. 核心要素与交互逻辑：折扣因子 γ 的意义

折扣因子 γ 是强化学习中的核心超参数，它直接控制未来奖励的权重与重要性，决定智能体在决策时是“目光短浅”，还是“深谋远虑”。

$$\gamma = 0$$

智能体只看重当前时刻的即时奖励，完全忽略所有未来的长期收益。

$$0 < \gamma < 1$$

兼顾当下与未来。这是最常用的设置。奖励随时间步长衰减，离当前越远的奖励对总回报的贡献越小。

$$\gamma = 1$$

未来任何时刻的奖励与当前奖励同等重要。适用于无限时域的任务，但需注意奖励和发散问题。

2. 核心要素与交互逻辑：马尔可夫决策过程(MDP)

MDP是描述强化学习问题的经典数学框架，由五元组构成：S, A, P, R, γ

S (State):状态集合

A (Action):动作集合

P (Transition Probability):状态转移概率 $P(s'|s,a)$


R (Reward Function):奖励函数 $R(s,a,s')$

γ (Discount Factor):折扣因子

马尔可夫性质

未来只依赖当前，与历史无关

$$P(s_{t+1}|s_t, a_t, s_{t-1}, a_{t-1}, \dots, s_1) = P(s_{t+1}|s_t, a_t)$$



2. 核心要素与交互逻辑：典型应用场景

强化学习特别擅长处理序列决策问题，即需要连续做出一系列决策，且当前的每一步选择都会直接影响未来的结果与收益的问题。这类问题在现实世界中普遍存在，也是传统方法较难解决的问题。

- 游戏AI
- 机器人控制
- 自动驾驶
- 推荐系统
- 资源调度与优化

3. 核心算法思想：价值函数

强化学习核心概念

奖励 (Reward) 很重要，但真正决定策略优劣的是价值 (Value)。

状态价值函数

定义：在策略 π 下，从状态 s 出发，未来能获得的期望总回报

$$V^{\pi}(s) = E_{\pi}[G_t | s_t = s]$$

直观理解：这个状态有多有前途？

动作价值函数

定义：在状态 s 下先执行动作 a 然后遵循策略 π ，未来能获得的期望总回报

$$Q^{\pi}(s, a) = E_{\pi}[G_t | s_t = s, a_t = a]$$

直观理解：在当前状态下，这个动作值不值得做？

3. 核心算法思想：优势函数

优势函数

$A^\pi(s, a)$: 这个动作比平均水平好多少？

定义

$$A^\pi(s, a) = Q^\pi(s, a) - V^\pi(s)$$

直观理解

- $A(s, a) > 0$: 采取该动作的收益优于该状态下的平均水平，应“鼓励”。
- $A(s, a) < 0$: 采取该动作的收益差于该状态下的平均水平，应“抑制”。
- $A(s, a) = 0$: 该动作的收益与平均水平持平，保持现状即可。

3. 核心算法思想: Bellman期望方程

核心思想

一个状态的价值, 本质上等于两部分之和

1. 从该状态执行动作后能立即获得的当前奖励 (Immediate Reward)
2. 到达下一个状态后, 未来能获得的、经过衰减系数 γ 折扣后的后续价值 (Discounted Future Value)

状态价值的贝尔曼期望方程 (状态好坏度量)

$$V^\pi(s) = \sum_{a \in A} \pi(a|s) \sum_{s', r} p(s', r|s, a) [r + \gamma V^\pi(s')]$$

两者关系:

动作价值的贝尔曼期望方程 (某个状态下, 某个动作好坏度量)

$$V^\pi(s) = \sum_{a \in A} \pi(a|s) Q^\pi(s, a)$$

$$Q^\pi(s, a) = \sum_{s', r} p(s', r|s, a) \left[r + \gamma \sum_{a'} \pi(a'|s') Q^\pi(s', a') \right]$$

3. 核心算法思想：Bellman最优方程

最优动作价值函数

$$Q^*(s, a) = \max Q^\pi(s, a)$$

评估当前状态下，某个特定动作的“上限”有多高


贝尔曼最优方程

$$Q^*(s, a) = \sum_{s', r} p(s', r | s, a) [r + \gamma \max_{a'} Q^*(s', a')]$$

当前动作的最优长期价值 = (这一步拿到的平均即时奖励) + (打折后的、未来你每一步都选最优动作所带来的最大收益)

4. 其它：探索与利用


利用 (Exploitation)



定义：根据当前经验，选择已知的、能带来最高回报的动作

风险：可能陷入“局部最优”

探索 (Exploration)



定义：尝试新的、不确定的动作，以获取更多关于环境的信息

风险：短期内回报可能较低，甚至导致失败

4. 其它：从概念到算法流派

1. 基于价值的方法 (Value-Based)

- **核心：**学习Q值函数，目标是找到能估计最优动作价值的Q值表或深度Q网络。
- **代表算法：**Q-learning、Deep Q-Network (DQN) 系列

1. 基于策略的方法 (Policy-Based)

- **核心：**直接对策略函数 $\pi(a|s)$ 进行参数化学习，通过优化策略参数来最大化期望累计回报。
- **代表算法：**Policy Gradient (PG)、Proximal Policy Optimization (PPO)

1. Actor-Critic方法

- **核心：**结合上述两类方法的优势。Actor 负责策略学习，Critic 负责价值估计，两者协作优化。
- **代表算法：**Advantage Actor-Critic (A2C)、Soft Actor-Critic (SAC)

5. 课程总结

强化学习是智能体 (Agent) 在与环境 (Environment) 的交互中, 通过试错学习策略 (Policy), 以最大化长期累积回报 (Return) 为目标的机器学习范式。

核心概念



智能体 (Agent)
学习并决策的主体,
根据策略选择动作。



环境 (Environment)
智能体所处的外部世界,
对动作做出响应。



状态 (State, s)
环境在某一时刻的描述,
智能体可观测到的信息。



动作 (Action, a)
智能体在状态 s 下可采取
的行为。



奖励 (Reward, r)
环境对动作的即时反馈,
用于指导学习。




策略 (Policy, π)
从状态到动作的映射,
 $\pi(a|s)$ 表示在 s 下采取 a
的概率。



回报 (Return, G_t)
从时刻 t 开始未来奖励的
累积, $G_t = \sum_{k=0}^{\infty} \gamma^k r_{t+k+1}$

智能体与环境的交互 (马尔可夫决策过程 MDP)



假设: 满足马尔可夫性 (未来只依赖于当前状态)

价值函数 (评估)

状态价值函数

$$V^{\pi}(s) = \mathbb{E}_{\pi} [G_t | s_t = s]$$

评估从状态 s 出发的期望回报

动作价值函数

$$Q^{\pi}(s, a) = \mathbb{E}_{\pi} [G_t | s_t = s, a_t = a]$$

评估在状态 s 采取动作 a 的
期望回报

策略 (决策)

$\pi(a|s)$: 在状态 s 下选择动作 a
的概率分布

评估
指导

产生
行为

反馈
学习

目标: 找到最优策略 π^*
使期望回报最大

探索与利用的权衡

探索 (Explore)

尝试未知动作
发现更优策略

利用 (Exploit)

选择已知最优动作
获取高回报

常见方法: ϵ -greedy, Softmax, UCB 等

学习目标

最大化期望的长期累积回报

$$J(\pi) = \mathbb{E}_{\pi} [G_t] = \mathbb{E}_{\pi} \left[\sum_{k=0}^{\infty} \gamma^k r_{t+k+1} \right]$$

- $\gamma \in [0, 1]$: 折扣因子, 权衡即时与未来奖励
- 最优策略: $\pi^* = \operatorname{argmax}_{\pi} J(\pi)$

常见强化学习算法 (按范式)



基于值的方法 (Value-based)

- 学习状态值或动作值函数
- 示例: Q-learning, DQN



基于策略的方法 (Policy-based)

- 直接优化策略
- 示例: REINFORCE, PPO



演员-评论家方法 (Actor-Critic)

- 结合值函数与策略优化
- 示例: A2C, A3C, DDPG, SAC

应用领域



游戏
(如 AlphaGo)



机器人控制



自动驾驶



推荐系统

.....

符号与记号

$s, s_t \in \mathcal{S}$

状态 (状态空间)

$a, a_t \in \mathcal{A}$

动作 (动作空间)

$r_t \in \mathcal{R}$

奖励

$P(s'|s, a)$

状态转移概率

$R(s, a)$

期望奖励

$\gamma \in [0, 1]$

折扣因子

$\pi(a|s)$

策略

$V^{\pi}(s), Q^{\pi}(s, a)$

价值函数

G_t

回报

✓ 强化学习的核心: 通过与环境的交互, 学习最优策略, 在不确定性中做决策, 以最大化长期累积回报。

