



中南大學

CENTRAL SOUTH UNIVERSITY

计算机视觉前沿技术

CSE

计算机学院

扩散模型与流匹配

主讲： 沈成超

邮箱： scc.cs@csu.edu.cn

2026.05.22

目录



0. 引言

1. 扩散模型

2. 流匹配

3. 二者关联

4. 大作业

0. 引言：生成模型背景

共同目标：模仿真实分布

核心问题

给定真实数据分布 $p_{data}(x)$ ，如何让模型学习并掌握其内在规律

关键任务

从简单、易采样的先验分布（如标准高斯分布 $z \sim N(0, I)$ ）出发，生成出与真实数据无法区分的高质量样本

数学目标

学习一个非线性映射函数，建立从低维随机噪声到高维真实数据的生成过程：

$$z \xrightarrow{\text{Generator}} x$$

主流方法

本次课程

- Diffusion Model
- Flow Matching

其他方法

GAN、VAE、Normalizing Flow

1. 扩散模型：扩散模型总览

扩散模型基本流程，分两步：

1.正向过程

通过逐步添加高斯噪声，将复杂的真实数据分布 $p_{data}(x)$ 转化为简单的标准高斯分布。

- 过程：

$$x_0 \rightarrow x_1 \rightarrow \dots \rightarrow x_t$$

- Tips:

x_0 : 原始真实图像数据

x_t : 近似纯随机高斯噪声

2.反向过程

扩散模型的核心训练目标：学习一个神经网络模型来模拟加噪过程的逆操作，从纯噪声中逐步恢复原始清晰数据。

- 过程：



$$x_t \rightarrow x_{t-1} \rightarrow \dots \rightarrow x_0$$

直觉来源

模型的灵感来源于物理学中的扩散过程（如墨水滴在清水中逐渐散开的现象）。

1. 扩散模型：前向过程

Forward Diffusion Process



Reverse Diffusion Process

前向过程可视化

核心定义：确定性加噪

一个固定的、马尔可夫式的加噪过程，将清晰图像逐步转化为纯高斯噪声：

$$q(x_t|x_{t-1}) = \mathcal{N}(x_t; \sqrt{1 - \beta_t}x_{t-1}, \beta_t I)$$

其中， β_t 为噪声强度； $t = 1, \dots, T$ ；随着 t 增大， β_t 增大

闭式解：

$$x_t = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{1 - \bar{\alpha}_t}\epsilon$$

1. 扩散模型：前向过程公式推导

1. 符号释义：

- $\mathbf{x}_0$: 原始数据样本
- $\mathbf{x}_t$: 第 t 步加噪后的样本
- $q(\mathbf{x}_t|\mathbf{x}_{t-1})$: 前向扩散的条件概率分布
- $N(\mathbf{x}; \mu, \Sigma)$: 高斯分布
- β_t : 第 t 步的噪声强度, 随步数增大 ($0 < \beta_t < 1$) $\Rightarrow$
- I : 单位矩阵, 噪声在各维度独立且方差为1

3. 新符号释义：

- α_t : 信息保留系数, 定义为 $\alpha_t = 1 - \beta_t$
- $\bar{\alpha}_t$: 累积信息保留系数, $\bar{\alpha}_t = \prod_{i=1}^t \alpha_i$ $\Rightarrow$

4. 重参数化：

- 高斯分布可以拆分为「确定性信号 + 随机噪声」, 方便采样和训练:

2. 单步加噪公式

$$q(x_t|x_{t-1}) = \mathcal{N}\left(x_t; \sqrt{1 - \beta_t}x_{t-1}, \beta_t I\right)$$



均值: $\sqrt{1 - \beta_t}x_{t-1}$, 原始信息被逐步削弱
方差: $\beta_t I$, 叠加的高斯噪声逐步变强



则可重写为：

$$q(x_t | x_{t-1}) = \mathcal{N}(x_t; \sqrt{\alpha_t}x_{t-1}, (1 - \alpha_t)I)$$



等价

$$x_t = \sqrt{\alpha_t}x_{t-1} + \sqrt{1 - \alpha_t}\varepsilon_t$$

1. 扩散模型：前向过程公式推导

由 $x_t = \sqrt{\alpha_t}x_{t-1} + \sqrt{1 - \alpha_t}\varepsilon_t$ 可从原始数据 x_0 出发，逐步递推到 x_t

1. 第一步加噪(t=1)

$$x_1 = \sqrt{\alpha_1}x_0 + \sqrt{1 - \alpha_1}\varepsilon_1, \quad \varepsilon_1 \sim \mathcal{N}(0, I)$$

2. 第二步加噪(t=2)

$$x_2 = \sqrt{\alpha_2}x_1 + \sqrt{1 - \alpha_2}\varepsilon_2$$

$$x_2 = \sqrt{\bar{\alpha}_2}x_0 + \sqrt{1 - \bar{\alpha}_2}\varepsilon', \quad \bar{\alpha}_2 = \alpha_1\alpha_2$$

将 x_1 代入可得：

$$\begin{aligned} x_2 &= \sqrt{\alpha_2}(\sqrt{\alpha_1}x_0 + \sqrt{1 - \alpha_1}\varepsilon_1) + \sqrt{1 - \alpha_2}\varepsilon_2 \\ &= \sqrt{\alpha_1\alpha_2}x_0 + \sqrt{\alpha_2(1 - \alpha_1)}\varepsilon_1 + \sqrt{1 - \alpha_2}\varepsilon_2 \end{aligned}$$

其中噪声项，根据高斯分布的可加性：

$$\sqrt{\alpha_2(1 - \alpha_1)}\varepsilon_1 + \sqrt{1 - \alpha_2}\varepsilon_2 = \sqrt{1 - \alpha_1\alpha_2}\varepsilon'$$

化简后得：

3. 第t步加噪，由数学归纳法：

$$x_t = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{1 - \bar{\alpha}_t}\varepsilon_t, \quad \varepsilon_t \sim \mathcal{N}(0, I)$$



证明可以直接从 x_0 采样任意时刻的
noisy sample x_t ，大大减少计算成本

1. 扩散模型：反向过程

学习目标

核心目标是通过学习，找到一个合适的分布来近似真实的反向条件概率分布

$q(x_{t-1}|x_t)$ ，从而让模型能从噪声中一步步恢复数据。

└─ 真实分布

模型参数化


└─ 预测分布

利用神经网络 $p_{\theta}(x_{t-1}|x_t)$ 输出高斯分布的均值和方差：

$$p_{\theta}(x_{t-1}|x_t) = \mathcal{N}(x_{t-1}; \mu_{\theta}(x_t, t), \Sigma_{\theta}(x_t, t))$$

核心任务：迭代去噪

在每一个时间步 t ，输入当前带噪样本 x_t 和时间信息 t ，让模型预测并减去其中的噪声，从而生成上一步更清晰的样本 x_{t-1}



1. 扩散模型：反向过程部分推导

实际训练中，最常用的方式不是直接预测均值 μ_θ ，而是预测噪声 ε 。

给定： x_t 和 t ，模型预测： $\varepsilon_\theta(x_t, t)$

根据： $x_t = \sqrt{\bar{\alpha}_t}x_0 + \sqrt{1 - \bar{\alpha}_t}\varepsilon_t, \quad \varepsilon_t \sim \mathcal{N}(0, I)$

解出 x_0 ： $x_0 = \frac{x_t - \sqrt{1 - \bar{\alpha}_t}\varepsilon}{\sqrt{\bar{\alpha}_t}}$

通过贝叶斯推导，反向过程的真实均值应该是： $\mu_t(x_t, x_0) = \frac{\sqrt{\alpha_t}(1 - \bar{\alpha}_{t-1})}{1 - \bar{\alpha}_t}x_t + \frac{\sqrt{\bar{\alpha}_{t-1}}\beta_t}{1 - \bar{\alpha}_t}x_0$

代入 x_0 ： $\mu_t(x_t, \varepsilon) = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}}\varepsilon \right) \Rightarrow$ 只要我们知道了噪声 ε ，我们就能计算出反向过程的均值 μ_t

预测噪声比预测均值好在哪：

- 噪声服从标准高斯分布，神经网络预测稳定
- 预测噪声的损失函数简单

1. 扩散模型：训练目标

前向过程：我们完全控制，给干净图片 x_0 加噪声，得到 x_t

反向过程：神经网络学习，给加噪图片 x_t ，预测噪声 ε_θ ，然后还原出 x_{t-1}

扩散模型的训练目标通常是对负对数似然的变分下界：

$$L_{VLB} = \mathbb{E}_{q(x_0)} \left[D_{KL}(q(x_T|x_0) \parallel p(x_T)) + \sum_{t=1}^T D_{KL}(q(x_{t-1}|x_t, x_0) \parallel p_\theta(x_{t-1}|x_t)) - \log p_\theta(x_0|x_1) \right]$$

- $q(x_T|x_0)$ ：前向过程最终的分布，在经过T步加噪后，趋近于标准高斯分布
 $p(x_T)$ ：假设的先验分布，在训练时人为定义为标准高斯分布
则第一项为两个完全一样的分布之间的KL散度，当然为0

- $-\log p_\theta(x_0|x_1)$ ：从 x_1 预测 x_0 的准确程度，非常小，可忽略不计

- $q(x_{t-1}|x_t, x_0)$ ：真实的反向分布
 $p_\theta(x_{t-1}|x_t)$ ：神经网络预测的反向分布

则原式：

$$L_{VLB} \approx \mathbb{E} \left[\sum_{t=1}^T D_{KL}(q(x_{t-1}|x_t, x_0) \parallel p_\theta(x_{t-1}|x_t)) \right]$$

则训练目标简化为：

让神经网络预测的反向分布，在所有时间步、所有图片上，都尽可能地接近真实的反向分布

1. 扩散模型：从变分下界到MSE

现在的问题只剩下如何计算两个高斯分布之间的KL散度

由于

- $q(x_{t-1}|x_t, x_0)$ 和 $p_\theta(x_{t-1}|x_t)$ 都是高斯分布
- 在原始 DDPM 中，固定了两个分布的方差，不让神经网络学习方差
- 两个方差相同的高斯分布之间的KL散度，**只和它们的均值有关**

可简化为：

$$D_{KL}(\mathcal{N}(\mu_1, \sigma^2) \parallel \mathcal{N}(\mu_2, \sigma^2)) = \boxed{\frac{1}{2\sigma^2}} \|\mu_1 - \mu_2\|^2$$

又由先前已证得：

$$\mu_t(x_t, \epsilon) = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{\beta_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon \right)$$

可得：

$$\|\mu_t - \mu_\theta\|^2 = \boxed{\frac{\beta_t^2}{\alpha_t(1 - \bar{\alpha}_t)}} \|\epsilon - \epsilon_\theta\|^2$$

最终的简化损失：

$$\mathcal{L}_{\text{simple}} = \mathbb{E}_{t, x_0, \epsilon} [\|\epsilon - \epsilon_\theta(x_t, t)\|^2]$$

与神经网络参数
无关的常数项

1. 扩散模型：其它理解角度

Score Matching

Score定义

$$\nabla_x \log p_t(x)$$

表示在某个噪声水平 t 下，样本 x 应该朝哪个方向移动，才能更接近高概率区域

对于加噪分布 $P_t(x)$ ，Diffusion Model实际上学习的是

$$s_\theta(x_t, t) \approx \nabla_{x_t} \log p_t(x_t)$$

噪声预测和score之间有关系

$$s_\theta(x_t, t) \approx -\frac{1}{\sqrt{1 - \bar{\alpha}_t}} \epsilon_\theta(x_t, t)$$

所以Diffusion Model可以被看作在不同噪声尺度上学习数据分布的 score field

SDE：随机微分方程

前向过程

$$dx = f(x, t)dt + g(t)dW_t$$

其中： $f(x, t)$ ：漂移项； $g(t)$ ：扩散系数； w_t ：布朗运动

反向过程

$$dx = [f(x, t) - g(t)^2 \nabla_x \log p_t(x)] dt + g(t)d\bar{W}_t$$

模型学习score：

$$\nabla_x \log p_t(x)$$

然后通过反向SDE从噪声生成样本

1. 扩散模型：采样方法

典型采样过程：

1. 从高斯分布采样

$$x_T \sim \mathcal{N}(0, I)$$

2. 对 $t = T, T - 1, \dots, 1$, 迭代去噪

$$x_{t-1} \sim p_\theta(x_{t-1} | x_t)$$

3. 最终得到

$$x_0$$

常见采样器包括：

DDPM sampler

DDIM sampler

PLMS

DPM-Solver

Euler sampler

Heun sampler

UniPC

EDM sampler

2. 流匹配：简述

核心动机：

直接学习一个连续时间的速度场，把简单分布连续变换成数据分布，而不一定依赖随机扩散或逐步去噪。

它试图解决Diffusion Model的一些问题：

- Diffusion Model的生成过程往往需要许多去噪步骤；
- score matching要学习的是score field，有时较间接；
- 随机扩散过程引入额外噪声，可能不是最短或最直接的传输路径；
- 希望统一Normalizing Flow、Diffusion、Optimal Transport等视角。



速度场可视化实例

2. 流匹配：数学基础

流匹配建立在连续归一化流 (CNF) 的概念之上，CNF定义了一个将一个概率分布转化为另一个概率分布的微分方程：

$$\frac{dx_t}{dt} = v_\theta(x_t, t)$$

其中 v_θ 为待学习的速度场



瞬时速度=此刻此处流速

在此流动下的概率密度演化遵循连续性方程：

概率密度   概率流量密度

$$\frac{\partial p_t(x)}{\partial t} + \nabla \cdot (p_t(x)v_t(x)) = 0$$

该方程确保变换过程中的质量守恒

2.流匹配：学习目标

目标是学习一个ODE: $\frac{dx_t}{dt} = v_\theta(x_t, t)$

使得: $x_0 \sim p_0$

简单分布, 如高斯噪声

经过流动后: $x_1 \sim p_1$

真实数据分布



换言之, 构造一族中间分布: $p_t, \quad t \in [0, 1]$

满足: $p_0 = \text{noise distribution}$ $p_1 = \text{data distribution}$

然后学习一个速度场 $v_\theta(x, t)$, 使得该速度场推动分布演化: $p_0 \rightarrow p_t \rightarrow p_1$

流匹配的核心就是拟合:

$$v_\theta(x, t) \approx v_t(x)$$

2.流匹配：流匹配原则

流匹配的核心创新在于直接通过预定义路径监督速度场 v_θ ，它无需从复杂概率流方程推导速度场，而是直接约束其与参考向量场 $u(x, t)$ 匹配。

参考向量场定义了样本应如何移动：

$$L_{\text{FM}} = \mathbb{E}_{t, x(t)} [\|v_\theta(x(t), t) - u(x(t), t)\|^2]$$

$u(x, t)$ ：一条从 p_0 到 p_1 的平滑路径

$x_{(t)}$ ：采样自噪声分布 $p_0(x)$ 到数据分布 $p_1(x)$ 之间的插值路径分布 $p_t(x)$

2.流匹配：条件流匹配

条件流匹配 (CFM) 是重要扩展，它在单个数据点与噪声样本之间构造路径：
参考向量场定义了样本应如何移动：

$$L_{\text{CFM}} = \mathbb{E}_{x_0, z, t} [\|v_\theta(x(t), t) - u(x(t), t; x_0, z)\|^2]$$


其中：

$$x(t) = (1 - t)z + tx_0 + \sigma(t)\epsilon$$

定义了噪声 z 和数据 x_0 之间的路径，而：

$$\epsilon \sim \mathcal{N}(0, I)$$

控制噪声路径。



3. 二者关联:多维度分析

扩散模型 (Diffusion Model)

核心思想

加噪再去噪的
逆向生成过程

数学对象

Score 得分函数
或 噪声 Noise

过程类型

随机 (SDE) /
确定性 (ODE)

训练目标

预测图像中的
噪声或Score

采样方式

多次反向去噪
迭代生成

采样效率

传统较慢
需加速采样器优
化

理论基石 & 比喻

Score Matching, SDE, VI
“擦掉画上的灰尘”

路径设计

由预设噪声 Schedule 决定
路径相对固定

流匹配 (Flow Matching)

核心思想

直接学习从噪声
到数据的速度场

数学对象

Velocity
向量场/速度场

过程类型

通常为 ODE
(全确定性过程)

训练目标

直接预测路径上
任意时刻的速度

采样方式

前向求解 ODE
生成过程连续

采样效率

天然适合少步采
样
速度优势明显

理论基石 & 比喻

CNF, Optimal Transport
“设计运输路线搬运点云”

路径设计

更灵活多样
支持线性/OT/Diffusion-like

3. 二者关联：路径与效率

Flow Matching vs DDPM

ODE Straight Path vs SDE Curved Path

DDPM (SDE)

1000 steps

Flow Matching (ODE)

10 steps



Speed

Speed

Slow (1000 NFE)

Fast (10 NFE)

图示：扩散模型 (左) 复杂的SDE曲线路径 vs 流匹配 (右) 灵活的ODE直线路径

流形空间中的轨迹生成差异决定了生成逻辑与效率上限



路径设计逻辑差异



扩散模型 (Diffusion)



流匹配 (Flow Matching)

路径严格由噪声Schedule决定，通常呈现为高维空间中的复杂曲线，生成过程受限于预设的加噪与去噪流程。

路径设计自由度极高，可优化为直线，生成过程受限于预设的加噪线或任意最优路径，无需遵循固定的噪声步骤



生成效率与性能



扩散模型 (Diffusion)



流匹配 (Flow Matching)

传统需要上千次迭代才能保证质量，虽然现代采样器可将步数降至几十步，但仍难以突破“多步”瓶颈。

适合“少步”甚至“一步”采样。通过ODE数值求解器可直接映射，更适合实时应用。

4. 大作业

一、报告基本信息

- **核心任务**: 选择一项你所了解的**计算机前沿技术**, 撰写一份包含深度分析与未来预测的技术报告。
- **选题范围**: 技术方向自选 (可结合前沿论文或核心技术方案)。
- **篇幅限制**: 5页以内。
- **核心原则**: 贵在精, 不在多。在保证内容意义完整、论证完善的前提下, 篇幅越精炼越好。

二、核心质量要求

1. 真实性与学术严谨度

- **严禁虚构**: 拒绝没有任何依据的凭空捏造。
- **文献支撑**: 所有核心技术分析、现状梳理和数据引用, 必须具备坚实的**文献依据**或**开源技术方案**支撑。

2. AI 辅助与独创性原则

- **禁止机械生成**: 纯靠 AI 批量灌水、毫无深度思考的流水线文章无法获得高分。
- **扩展认知边界**: 可以合理使用 AI 辅助工具 (如润色、查阅资料、梳理框架), 但报告必须展现出**新意**, 能够提供令人眼前一亮的实质性内容。

三、报告提分项 (亮点与深度)

一份优秀的报告应超越简单的“技术盘点”, 建议包含以下深度思考:

- **创新性观点**: 在现有前沿技术的基础上, 提出你自己的独到见解、改进方向或未来融合趋势, 并给出严密的**逻辑分析**。
- **实验验证思路**: 针对你的创新观点, 阐述一套可行的**实验设计方案**或**技术验证路径** (如何用数据/实验证明你是对的)。
- **辩证性反思**: 客观分析该技术目前可能存在的**不足**、**局限性**或潜在的落地挑战。

四、排版与格式规范

- **技术工具**: 全篇使用 **Markdown** 语法编写。
- **视觉可读**: 整体排版必须结构清晰、层次分明、易于快速浏览 (合理使用标题、加粗和列表)。